



Aprendizagem de Máquina 2026 Trabalho 1 Métodos de Classificação e Regressão

O objetivo do primeiro trabalho da disciplina consiste em comparar o comportamento, em termos de métrica de avaliação (Acurácia, F1-score, AUC, RMSE, MAE, etc.) de modelos baseados em diferentes conceitos sobre uma mesma base de dados. Além disso, pretende-se comparar algumas estratégias de combinação desses modelos e analisar se a adoção da combinação leva a melhores taxas de desempenho.

Para que o processo tenha base para análise, deverão ser executadas 20 repetições de forma que os valores a serem comparados deverão ser os valores médios das 20 execuções.

O primeiro passo consistirá na divisão estratificada da base original em três subconjuntos mutuamente exclusivos: treino, teste e validação (Conforme apresentado na Figura 1). A instância que for designada para um conjunto não deve aparecer nos outros.

O conjunto de treino deverá conter 50% do tamanho do dataset original. Já as bases de validação e teste, terão 25% da dimensão inicial.




Figura 1. Divisão estratificada do conjunto de entrada

IMPORTANTE 1: no momento de separar a base original nos três conjuntos (treino, teste e validação), deve-se manter as proporções originais das classes. Por exemplo, se um conjunto possui 200 instâncias da classe A e 100 da classe B, o conjunto de treino terá 100 instâncias da classe A e 50 da classe B.

IMPORTANTE 2: a escolha das instâncias que formarão cada um dos conjuntos deve ser totalmente aleatória.

IMPORTANTE 3: lembre-se de sempre “bagunçar” os conjuntos de dados antes de fazer a divisões e de realizar o treinamento. A adoção de aleatoriedade adiciona robustez ao processo.

Depois de formados os conjuntos, o passo seguinte será o treinamento dos modelos de classificação ou regressão. Nesta tarefa deverão ser implementadas as estratégias dos K Vizinhos mais próximos (KNN), Árvore de Decisão (AD), Naive Bayes (NB), Máquina de Vetor de Suporte (SVM) e Multilayer Perceptron (MLP). Além disso, deverão ser implementadas as estratégias baseadas em sistemas de múltiplos classificadores de Floresta Aleatória (Random Forest - RF), Bagging e Boosting, a combinação dos 5 modelos individuais pelas regras da soma, pelo voto majoritário e pela estratégia Borda Count.

Para se determinar quais os melhores hiperparâmetros de cada estratégia, deve-se adotar o conjunto de validação (conforme ilustrado na Figura 2). Por exemplo, digamos que estamos treinando um KNN e queremos decidir qual o melhor K a ser empregado. Deve-se treinar o classificador com o conjunto de treino e então variar o valor de K e analisar quanto o classificador acerta do conjunto de validação. O valor de K que levar à maior acurácia (ou menor taxa de erros) é usado no momento de classificar o conjunto de teste.

Os hiperparâmetros que deverão ser variados para cada modelo de classificação são detalhados na Tabela 1 apresenta a seguir.




Figura 2. Adoção do conjunto de validação na estimação dos parâmetros

Tabela 1. Detalhamento de quais hiperparâmetros avaliar para cada modelo utilizado

KNN	• Número de vizinhos • Ponderação (não ponderado, ponderado pelo inverso da distância euclidiana, ponderado por 1-distância normalizada)
AD	• Critério de seleção dos atributos • Divisor dos atributos (Splitter) • Profundidade máxima • Número mínimo para realizar a divisão do nó • Número mínimo de elementos por folha
NB	• Não precisa variar hiperparâmetros
SVM	• Valor do erro (C) • Tipo de Kernel
MLP	• Número de épocas de treino • Taxa de aprendizagem • Número de camadas escondidas • Quantidade de neurônios em cada camada escondida • Função de ativação • Tamanho do batch
RF	• Número de estimadores • Critério de seleção dos atributos • Profundidade máxima • Número mínimo para realizar a divisão do nó • Número mínimo de elementos por folha
Bagging	• Número de estimadores • Número de amostras para cada subconjunto • Estimadores (os classificadores empregados terão seus hiperparâmetros setados com os valores default)
Boosting	• Número de estimadores • Estimadores (os classificadores empregados terão seus hiperparâmetros setados com os valores default) • Taxa de aprendizado

Além dos cinco modelos monolíticos implementados, deverão ser implementadas duas estratégias baseadas em Sistemas de Múltiplos Classificadores (SMC): Bagging, Random Forest e Boosting. Ambas as estratégias devem também ser submetidas ao processo de treinamento e calibração, assim como os métodos individuais.

Por fim, a equipe deverá implementar três abordagens de combinação de classificadores:

- Regra da Soma

- Voto Majoritário
- Borda Count

Estas abordagens devem combinar a opinião dos cinco classificadores desenvolvidos na primeira etapa do trabalho (KNN, SVM, NB, AD e MLP).

IMPORTANTE 4: Os métodos de combinação empregam os modelos monolíticos já treinados e calibrados. Não se deve realizar todo o processo novamente, apenas trabalhar com os modelos já construídos.

IMPORTANTE 5: uma vez que as estratégias de combinação utilizam o percentual de confiança do voto de cada classificador, recomendo que, no momento de avaliar os classificadores (sobre o conjunto de testes), sejam salvos esses percentuais de confiança de cada classificador para cada instância. Dessa forma ganha-se tempo na execução do trabalho.

Definidos os melhores parâmetros para cada classificador, o passo seguinte será avaliar os seus desempenhos sobre o conjunto de teste (tal processo é ilustrado na Figura 3). Nesta etapa deverá ser guardada a medida de desempenho escolhida de cada classificador/regressor ao longo das 20 execuções. Ao término desta etapa, terão sido obtidos 100 valores de desempenho (20 para cada classificador/regressor) para os modelos monolíticos e baseados em SMC.




Figura 3. Avaliação do desempenho dos classificadores sobre o conjunto de teste

A última etapa consiste na comparação estatística das medidas de desempenho alcançadas pelos métodos para descobrir qual deles obteve o melhor desempenho. Para tanto, deve-se executar dois testes estatísticos. O primeiro servirá para detectar se há diferença entre o desempenho dos algoritmos (independente de qual foi melhor ou pior). O segundo teste estatístico serve para comparar, dois a dois, os classificadores com o objetivo de avaliar se eles têm desempenhos significativamente diferentes e quem é o melhor.

Para esta etapa deverão ser empregados métodos estatísticos não paramétricos, considerando confiança de 95%.

COMO FAZER?

Não é necessário implementar os métodos de classificação. Neste caso, pode-se, e é indicado, que sejam utilizadas implementações prontas dos métodos, ficando a cargo da dupla apenas a implementação do framework e análise dos parâmetros escolhidos e dos resultados.

Da mesma forma, para o carregamento, aleatorização, divisão e sorteio dos conjuntos de treino, teste e validação podem ser utilizadas funções próprias das linguagens.

Caso a linguagem tenha implementada as soluções de combinação elencadas acima, a dupla poderá fazer uso delas nos experimentos, sem ter que reimplementá-las.

O QUE DEVE SER ENTREGUE

Relatório em formato pdf detalhado contendo a descrição da base de dados. O documento deve, **obrigatoriamente**, seguir a formatação de artigos especificado pela SBC conforme documentos disponíveis no endereço <https://drive.google.com/file/d/1202IC9vi1dW7E7ZAQsj8IP4eJZBXVbIV/view?usp=sharing>.

No relatório, cada equipe deve detalhar a base de dados utilizada. Deve-se explicar sobre os atributos e classes presentes no dataset. Além disso, é necessário explicar as características do conjunto de dados no contexto do aprendizado de máquina, como distribuição das classes, tipos de atributos, número de amostras etc.

Deve-se detalhar quais foram os parâmetros empregados em cada método de classificação e em qual faixa de valores cada parâmetro foi variado. Por exemplo, no KNN, seria possível variar o valor de k entre 1 e 20.

Devem ser apresentadas, através de tabelas (**não figuras**) as acurácias e desvios padrões obtidos por cada classificador ao longo das 20 repetições, conforme exemplificado a seguir.

Repetição	KNN	AD	NB	SVM	MLP
1	Acc	Acc	Acc	Acc	Acc
2	Acc	Acc	Acc	Acc	Acc
...	...	...	...	...	...
20	Acc	Acc	Acc	Acc	Acc
	Média (DP)	Média (DP)	Média (DP)	Média (DP)	Média (DP)

O relatório deve conter a análise estatística indicando se há diferença significativa no desempenho dos métodos, ou seja, se há algum classificador que seja diferente dos demais.

A análise deve mostrar quais classificadores tiveram desempenho similar e quais foram mais acurados durante o processo.

Deve-se também apresentar uma tabela similar com os resultados obtidos pelas estratégias de combinação (Soma, Produto e Borda Count) e de ensemble (SMC).

Repetição	Bagging	RF	Boosting	Soma	Produto	Borda Count
1	Acc	Acc	Acc	Acc	Acc	Acc
2	Acc	Acc	Acc	Acc	Acc	Acc
...	...	...	...	...	...	...
20	Acc	Acc	Acc	Acc	Acc	Acc
	Média (DP)	Média (DP)	Média (DP)	Média (DP)	Média (DP)	Média (DP)

Em seguida, deve-se efetuar análise estatística comparando os desempenhos das abordagens de combinação e indicar se existe pelo menos um método diferente dos demais.

Por fim, deve-se comparar o desempenho do melhor método de classificação monolítica (individual) com o melhor método de combinação e/ou ensemble e apontar qual abordagem foi mais interessante.

Nesta análise também deve-se verificar se há diferença significativa em termos estatísticos.

PARA QUANDO?

O trabalho deverá ser submetido no link disponibilizado no Microsoft Teams até as **12:00 do dia 22/05/2026**.

As apresentações serão realizadas nas aulas do dia 25 e 26/05.

Cada grupo terá 15 minutos para apresentar o trabalho realizado, focando na descrição do problema, nos desempenhos obtidos e no resultado da análise estatística.

A ordem das apresentações será definida através de sorteio de forma que todos deverão estar presentes. Por tratar-se de uma avaliação, caso a equipe sorteada não esteja em sala ela perderá o direito de realizar sua apresentação.